

АНАЛИТИЧЕСКИЙ ОТЧЁТ

по курсовому проекту «Классическое машинное обучение»

Тема:

Прогнозирование эффективности лекарственных препаратов на основе молекулярных дескрипторов

Студент: Лучин Илья Игоревич

Дата: 27.04.2026 г.

Оглавление

1. Введение	3
2. Характеристика данных	4
2.1 Исходная выборка	4
2.2 Описание целевых переменных	4
3. EDA анализ данных.....	5
3.1 Предварительная обработка данных	5
3.2 Статистика выбросов (метод IQR)	5
3.3 Логарифмическое преобразование	5
3.4 Итоговая выборка для моделирования	5
3.5 Распределение классов	5
3.6 Визуализации EDA	6
4. Регрессионный анализ	10
4.1 Прогнозирование IC50	10
4.2 Прогнозирование CC50	10
4.3 Прогнозирование SI.....	11
5. Классификация.....	13
5.1 IC50 > медианы	13
5.2 CC50 > медианы	13
5.3 SI > медианы	14
5.4 SI > 8	15
6. Сводные результаты.....	17
6.1 Сводная таблица результатов	17
6.2 Анализ доминирующих моделей	17
6.4 Анализ переобучения	18
7. Выводы и рекомендации.....	19
7.1 Основные результаты проекта	19
7.2 Заключение	19

1. Введение

Цель проекта

Построение прогнозных моделей для подбора наиболее эффективных параметров создания лекарственных препаратов на основе экспериментальных данных химиков.

Задачи исследования

1. Провести разведочный анализ данных (EDA) с применением статистических методов и визуализации
2. Построить модели регрессии для предсказания:
 - IC50 (эффективность против вируса)
 - CC50 (цитотоксичность)
 - SI (индекс селективности)
3. Построить модели классификации для определения:
 - Превышает ли IC50 медианное значение
 - Превышает ли CC50 медианное значение
 - Превышает ли SI медианное значение
 - Превышает ли SI порог 8
4. Сравнить модели, проанализировать результаты и сформулировать обоснованные выводы

Актуальность

От качества проведённого анализа зависит эффективность и состав разрабатываемого лекарственного препарата. Автоматизация подбора параметров позволяет ускорить процесс drug discovery и снизить затраты на разработку.

2. Характеристика данных

2.1 Исходная выборка

Параметр	Значение
Количество образцов	1001 соединений
Количество признаков	214 молекулярных дескрипторов
Целевые переменные	IC50, CC50, SI (и их логарифмы)
Источник данных	Экспериментальные данные химиков

2.2 Описание целевых переменных

Переменная	Описание	Интерпретация
IC50, mM	Концентрация для 50% ингибирования вируса	Чем меньше, тем эффективнее
CC50, mM	Концентрация для 50% цитотоксичности	Чем больше, тем безопаснее
SI	Индекс селективности: $SI = CC50 / IC50$	Чем больше, тем лучше

Пороговые значения:

$SI > 8$ — общепринятый стандарт в фармацевтике для отбора перспективных соединений

$SI > \text{медиана}$ — относительная оценка селективности в рамках выборки

3. EDA анализ данных

3.1 Предварительная обработка данных

Этап	Операция	Результат
1. Проверка целостности	Анализ пропущенных значений	<5% пропусков → удалены
2. Дубликаты	Поиск дубликатов строк	Не обнаружены
3. Валидация формул	Проверка $SI = CC50 / IC50$	Формула подтверждена
4. Выбросы (IQR метод)	Обнаружение аномалий	Сохранены (активные лиды)
5. Логарифмирование	Применение $\log_{10}(x)$	Снижена асимметрия
6. Константные признаки	Удаление $std < 10^{-6}$	Удалены
7. Технические столбцы	Удаление 'Unnamed', 'index'	Удалены
8. Мультиколлинеарность	Анализ корреляций > 0.95	Обнаружены пары

3.2 Статистика выбросов (метод IQR)

Переменная	Количество выбросов	Процент
IC50	~10% выборки	Умеренное количество
CC50	~8% выборки	Умеренное количество
SI	~12% выборки	Повышенное количество

Обоснование сохранения выбросов:

В задачах drug discovery выбросы часто соответствуют наиболее активным или токсичным соединениям — именно эти образцы представляют наибольший интерес для исследователей. Удаление привело бы к потере важной информации о потенциальных лекарственных кандидатах.

3.3 Логарифмическое преобразование

Применено преобразование $\log_{10}(x) = \log(x + 1)$ для всех целевых переменных с целью:

- Снижения положительной асимметрии распределений
- Стабилизации дисперсии
- Уменьшения влияния выбросов
- Приведения распределений к более нормальному виду

3.4 Итоговая выборка для моделирования

Параметр	Значение
Количество образцов	998 соединений
Количество признаков	~207 дескрипторов
Разделение train/test	80% / 20% (798 / 200)
Стратификация	Применена для классификации
Масштабирование	RobustScaler
Random State	42
Кросс-валидация	5-fold CV

3.5 Распределение классов

Задача	Класс 0	Класс 1	Баланс
IC50 > медиана	499 (50.0%)	499 (50.0%)	Сбалансировано
CC50 > медиана	500 (50.1%)	498 (49.9%)	Сбалансировано
SI > медиана	499 (50.0%)	499 (50.0%)	Сбалансировано
SI > 8	642 (64.3%)	356 (35.7%)	Дисбаланс

Методы балансировки:

- Для задачи $SI > 8$ применён параметр `class_weight='balanced'` во всех моделях
- Стратифицированное разбиение для сохранения пропорций классов в train/test выборках

3.6 Визуализации EDA

В ходе разведочного анализа построены следующие графики:

- Гистограммы распределений IC50, CC50, SI (оригинальные и логарифмированные значения) → Показали положительную асимметрию всех целевых переменных (рис.1)
- Boxplot для визуализации выбросов до и после логарифмирования → Продemonстрировали эффективность log-преобразования для сжатия хвостов (рис.2)
- Heatmap корреляций целевых переменных → Выявили слабую корреляцию между IC50 и CC50 (задачи решаются независимо) (рис.3)
- PCA визуализация признакового пространства (PC1 vs PC2, цвет = $\log(SI)$) → Показали размытую структуру данных → требуются нелинейные модели (рис.4)

Рис.1 Гистограммы распределений




Рис.2 Вохplot выбросов до и после логарифмирования




Рис.3 Heatmap корреляций целевых переменных





Рис.4 PCA визуализация признакового пространства (PC1 vs PC2, цвет = $\log(SI)$)



4. Регрессионный анализ

4.1 Прогнозирование IC50

Цель: Предсказание концентрации IC50 для оценки эффективности препарата

Методы:

- Random Forest Regressor
- Gradient Boosting Regressor
- XGBoost Regressor
- LightGBM Regressor
- Ridge Regression

Параметры GridSearchCV:

- Scoring: R^2
- Cross-validation: 5-fold
- Оптимизация гиперпараметров для каждой модели

Результаты:

Модель	CV R^2	Test R^2	Test RMSE	Статус
LightGBM	0.414	0.469	1.439	Лучшая
XGBoost	0.414	0.467	1.442	—
Random Forest	0.455	0.461	1.450	—
Gradient Boosting	0.434	0.448	1.467	—
Ridge	0.121	0.288	1.326	Недообучение

Лучшая модель: LightGBM (Test $R^2 = 0.469$)

Разрыв CV-Test: +0.055 (стабильно)

Выводы:

- Ансамбли деревьев превзошли линейную модель (Ridge)
- LightGBM показал наилучший баланс между смещением и дисперсией
- $R^2 = 0.469$ — хороший результат для хемоинформатики
- Модель не переобучена, разрыв CV-Test в пределах нормы

Лучшие гиперпараметры LightGBM:

- learning_rate: 0.05
- n_estimators: 100

4.2 Прогнозирование CC50

Цель: Предсказание концентрации CC50 для оценки токсичности препарата

Результаты:

Модель	CV R^2	Test R^2	Test RMSE	Статус
Random Forest	0.455	0.372	1.246	Лучшая
XGBoost	0.414	0.364	1.253	—
LightGBM	0.431	0.360	1.257	—
Gradient Boosting	0.434	0.352	1.265	—
Ridge	0.121	0.288	1.326	Недообучение

Лучшая модель: Random Forest (Test $R^2 = 0.372$)

Разрыв CV-Test: -0.084 (переобучение)

Выводы:

- Обнаружено переобучение (разрыв CV-Test превышает порог 0.05)
- Random Forest показал лучшую устойчивость к шуму
- CC50 предсказывается хуже IC50, что может указывать на большую вариабельность токсичности
- Линейная модель снова показала низкое качество

Рекомендации:

- Увеличить регуляризацию (параметры min_samples_leaf, max_depth)
- Применить отбор признаков (SelectKBest, feature importance)
- Использовать RepeatedKfold для более стабильной оценки

Лучшие гиперпараметры Random Forest:

- max_depth: 10
- n_estimators: 100

4.3 Прогнозирование SI

Цель: Предсказание индекса селективности ($SI = CC50 / IC50$)

Особенности задачи: SI — производная величина, ошибки IC50 и CC50 суммируются

Результаты:

Модель	CV R^2	Test R^2	Test RMSE	Статус
Random Forest	0.299	0.381	1.280	Лучшая
XGBoost	0.253	0.373	1.288	—
LightGBM	0.278	0.356	1.306	—
Gradient Boosting	0.283	0.329	1.333	—
Ridge	0.181	0.173	1.479	Недообучение

Лучшая модель: Random Forest (Test $R^2 = 0.381$)

Разрыв CV-Test: +0.082 (стабильно)

Выводы:

- Положительный разрыв CV-Test указывает на удачное разбиение выборки
- $R^2 = 0.381$ — ожидаемый результат для производной величины
- Random Forest показал стабильность и устойчивость
- Все ансамбли работают похоже (разброс 0.02)

Рекомендации:

- Для улучшения качества требуется feature engineering
- Возможно создание полиномиальных признаков
- Рассмотреть многозадачное обучение (совместное предсказание IC50 и CC50)

Лучшие гиперпараметры Random Forest:

- max_depth: 10
- n_estimators: 100

5. Классификация

5.1 IC50 > медианы

Цель: Бинарная классификация соединений на эффективные (IC50 > медиана) и неэффективные

Метрики:

- ROC-AUC (основная метрика оптимизации)
- Accuracy, Precision, Recall, F1-score

Результаты:

Модель	CV ROC-AUC	Test ROC-AUC	Test F1	Статус
Random Forest	0.795	0.802	0.743	Лучшая
XGBoost	0.790	0.789	0.714	—
Gradient Boosting	0.806	0.779	0.721	—
LightGBM	0.788	0.778	0.706	—
Logistic Regression	0.762	0.742	0.705	—

Лучшая модель: Random Forest (Test ROC-AUC = 0.802)

Разрыв CV-Test: +0.007 (отличная стабильность)

Анализ матрицы ошибок (Random Forest):

- True Positive: 75
- True Negative: 73
- False Positive: 27
- False Negative: 25

Баланс ошибок: модель симметрично ошибается на обоих классах

Выводы:

- ROC-AUC = 0.802 — отличный результат для бинарной классификации
- Модель не переобучена (разрыв CV-Test минимален)
- Random Forest превзошёл линейную модель, что говорит о нелинейной природе зависимостей
- Баланс Precision/Recall приемлемый

Лучшие гиперпараметры Random Forest:

- max_depth: 10
- n_estimators: 100

5.2 CC50 > медианы

Цель: Классификация соединений на безопасные (CC50 > медиана) и токсичные

Результаты:

Модель	CV ROC-AUC	Test ROC-AUC	Test F1	Статус
LightGBM	0.841	0.859	0.763	Лучшая
XGBoost	0.835	0.858	0.759	—
Random Forest	0.837	0.855	0.762	—
Gradient Boosting	0.843	0.834	0.748	—
Logistic Regression	0.815	0.794	0.712	—

Лучшая модель: LightGBM (Test ROC-AUC = 0.859)

Разрыв CV-Test: +0.018 (стабильно)

Анализ матрицы ошибок (LightGBM):

- True Positive: 79
- True Negative: 72
- False Positive: 28
- False Negative: 21

Наблюдение: модель немного чаще ошибается на классе 0 (ложноположительные), что безопаснее для токсичности

Выводы:

- ROC-AUC = 0.859 — лучший результат среди всех задач!
- Цитотоксичность (CC50) лучше всего предсказывается молекулярными дескрипторами
- LightGBM показал небольшое преимущество над XGBoost и Random Forest
- Модель устойчива, разрыв CV-Test минимален

Лучшие гиперпараметры LightGBM:

- learning_rate: 0.05
- n_estimators: 100

5.3 SI > медианы

Цель: Классификация соединений на селективные (SI > медиана) и неселективные

Особенности задачи:

- SI — производная величина, что усложняет классификацию
- Ошибки предсказания IC50 и CC50 суммируются

Результаты:

Модель	CV ROC-AUC	Test ROC-AUC	Test F1	Статус
Random Forest	0.745	0.690	0.605	Лучшая
Gradient Boosting	0.733	0.685	0.604	—
LightGBM	0.753	0.676	0.605	—
Logistic Regression	0.673	0.674	0.644	—
XGBoost	0.744	0.672	0.623	—

Лучшая модель: Random Forest (Test ROC-AUC = 0.690)

Разрыв CV-Test: -0.055 (переобучение)

Анализ матрицы ошибок (Random Forest):

- True Positive: 59
- True Negative: 64
- False Positive: 36
- False Negative: 41

Наблюдение: модель чаще пропускает селективные соединения ($FN > FP$)

Выводы:

- ROC-AUC = 0.690 — умеренный результат, ниже чем у IC50 и CC50
- Обнаружено переобучение ($CV R^2 \approx 0.74-0.75$, $Test R^2 \approx 0.67-0.69$)
- Все модели работают похоже (разброс 0.02) — это предел информативности признаков
- Гистограмма показывает сильное перекрытие распределений вероятностей

Рекомендации:

- Применить более сильную регуляризацию
- Использовать отбор признаков (SelectFromModel)
- Рассмотреть создание дополнительных признаков (взаимодействия дескрипторов)

Лучшие гиперпараметры Random Forest:

- max_depth: 10
- n_estimators: 100

5.4 SI > 8

Цель: Классификация соединений по абсолютному порогу селективности ($SI > 8$)

Практическая значимость:

- $SI > 8$ — общепринятый стандарт в фармацевтике
- Наиболее практико-ориентированная задача
- Классы не сбалансированы (35.7% vs 64.3%)

Результаты:

Модель	CV ROC-AUC	Test ROC-AUC	Test F1	Статус
Random Forest	0.743	0.732	0.556	Лучшая
LightGBM	0.732	0.717	0.606	—
Logistic Regression	0.695	0.713	0.563	—
XGBoost	0.731	0.711	0.543	—
Gradient Boosting	0.739	0.678	0.558	—

Лучшая модель: Random Forest (Test ROC-AUC = 0.732)

Разрыв CV-Test: -0.011 (стабильно)

Анализ матрицы ошибок (Random Forest):

- True Positive: 37 (правильно найдены селективные)
- True Negative: 104 (правильно отброшены неселективные)
- False Positive: 25 (ложная тревога)
- False Negative: 34 (пропущены селективные)
- Recall = 52.1% — модель находит половину перспективных соединений

Практическая интерпретация:

- В тестовой выборке: 71 реально селективное соединение ($SI > 8$)
- Модель нашла: 62 соединения
- Правильно найдено: 37 (TP)
- Пропущено: 34 (FN)

Выводы:

- ROC-AUC = 0.732 — хороший результат для несбалансированных данных
- Random Forest показал лучшую ROC-AUC, но LightGBM имеет лучший F1 и Recall
- Для drug discovery важнее Recall (не пропустить активные), чем Precision
- Модель стабильна, переобучение отсутствует

Рекомендации:

- Снизить порог классификации с 0.5 до 0.3-0.4 для повышения Recall
- Использовать LightGBM если важен баланс Precision/Recall ($F1 = 0.606$)
- Использовать Random Forest если важна общая дискриминационная способность ($AUC = 0.732$)

Лучшие гиперпараметры Random Forest:

- max_depth: 10
- n_estimators: 100

6. Сводные результаты

6.1 Сводная таблица результатов

Регрессии:

Задача	Лучшая модель	Test R ²	CV-Test	Оценка
IC50	LightGBM	0.469	+0.079	Хорошо
CC50	Random Forest	0.372	-0.084	Переобучение
SI	Random Forest	0.381	+0.082	Стабильно

Классификации:

Задача	Лучшая модель	ROC-AUC	CV-Test	Оценка
IC50 > медиана	Random Forest	0.802	+0.007	Отлично
CC50 > медиана	LightGBM	0.859	+0.018	Прекрасно
SI > медиана	Random Forest	0.690	-0.055	Переобучение
SI > 8	Random Forest	0.732	-0.011	Хорошо

6.2 Анализ доминирующих моделей

Random Forest: Лучшая модель в 5 из 7 задач (71%)

Преимущества:

- Устойчивость к шуму и выбросам
- Хорошая работа с молекулярными дескрипторами
- Минимальная настройка гиперпараметров
- Интерпретируемость (feature importance)

Недостатки:

- Склонность к переобучению на маленьких выборках
- Медленнее градиентных бустингов

LightGBM:

- Лучшая модель в 2 задачах (CC50 регрессия и классификация)
- Преимущества:
 - Высокая скорость обучения
 - Отличное качество на структурированных данных
 - Эффективная работа с категориальными признаками
- Показал лучший результат проекта: ROC-AUC = 0.859 (CC50 классификация)

XGBoost:

- Стабильные результаты во всех задачах
- Часто занимает 2-3 место
- Требуется более тщательной настройки гиперпараметров

Линейные модели (Ridge, Logistic Regression):

- Систематически уступают ансамблям деревьев
- Причина: нелинейные зависимости между дескрипторами и целевыми переменными
- Могут быть полезны как базовые модели (baseline)

6.4 Анализ переобучения

Задачи с переобучением (разрыв CV-Test < -0.05):

1. CC50 регрессия (-0.084)

- Причина: маленькая выборка (n=998) + высокая размерность
- Решение: увеличить регуляризацию, отбор признаков

2. SI > медиана (-0.055)

- Причина: производная величина, накопление ошибок
- Решение: feature engineering, создание взаимодействий

Задачи со стабильными результатами:

- Все остальные задачи показали разрыв CV-Test в пределах ± 0.05
- Модели хорошо обобщают данные
- Cross-validation работает корректно

7. Выводы и рекомендации

7.1 Основные результаты проекта

1. Построено 7 моделей классического машинного обучения:

- 3 задачи регрессии (IC50, CC50, SI)
- 4 задачи классификации (IC50 > медиана, CC50 > медиана, SI > медиана, SI > 8)

2. Лучшие результаты:

- CC50 > медиана: ROC-AUC = 0.859 (LightGBM)
- IC50 > медиана: ROC-AUC = 0.802 (Random Forest)
- IC50 регрессия: $R^2 = 0.469$ (LightGBM)

3. Доминирующая модель: Random Forest (лучшая в 5 из 7 задач)

4. Все модели превосходят бейзлайн, что подтверждает наличие предсказательного сигнала в молекулярных дескрипторах

7.2 Заключение

В ходе выполнения курсового проекта:

- Проведён полноценный разведочный анализ данных (EDA) с визуализацией
- Построено 7 моделей классического машинного обучения
- Выполнен сравнительный анализ 5 алгоритмов (RF, GB, XGBoost, LightGBM, Ridge/LR)
- Проведена настройка гиперпараметров через GridSearchCV с кросс-валидацией
- Получены интерпретируемые результаты с практическими рекомендациями
- Выявлены сильные и слабые стороны каждого подхода

Наиболее значимые достижения:

- ROC-AUC = 0.859 для предсказания цитотоксичности (CC50)
- ROC-AUC = 0.802 для предсказания эффективности (IC50)
- Random Forest показал себя как универсальная и надёжная модель

Практическая ценность:

Разработанные модели могут быть использованы для:

- Первичного скрининга потенциальных лекарственных соединений
- Приоритизации кандидатов для синтеза и тестирования
- Снижения затрат на разработку препаратов
- Ускорения процесса drug discovery

Проект демонстрирует эффективность классических методов машинного обучения в хемоинформатике и открывает возможности для дальнейших исследований с применением более сложных подходов (GNN, multi-task learning, active learning).

Работа имеет ряд ограничений: размер выборки ($n=998$) ограничивает потенциальную точность моделей, а использование только 2D-молекулярных дескрипторов не учитывает пространственную структуру соединений. Для промышленного применения необходима внешняя валидация на независимых датасетах (например, ChEMBL) и калибровка предсказаний под конкретные пороги отбора.